陈欣骅

chenxh26@mails.tsinghua.edu.cn

研究兴趣：通过软硬件协同设计构建高效 AI 系统，重点关注 AI 计算架构、面向 AI 的内存系统，以及模型与架构的协同演进。

教育经历

- **清华大学，交叉信息研究院（IIIS）** 2026 年 9 月 – 至今

  计算机系统结构方向，博士研究生

  - **会议审稿**: 担任国际学习表征会议（ICLR）审稿人。

- **复旦大学，集成电路与微纳电子创新学院** 2021 年 9 月 – 2026 年 6 月

  微电子科学与工程专业，工学学士

  - **成绩**: GPA 3.78/4.00，专业排名 13/137。
  - **荣誉**: 2026 年上海市优秀毕业生（137 人中 7 人）；2022 年徐增寿奖学金（约 130 人中 1 人）。
  - **奖项**: 2022 年全国大学生数学建模竞赛"高教社杯"国家二等奖；2023 年本科二等奖学金。
  - **科研经历**: 研究全同态加密加速器调度、基于大语言模型的 RTL 生成和零样本 HDR 色调映射；以共同第一作者身份发表 ISEDA 2025 和 GLSVLSI 2025 论文，并参与 CVPR 2024 Highlight 论文。

实习经历

- **北极雄芯** 2026 年 7 月 – 至今

  芯片架构师 导师：谭展宏博士

  - **职责**: 探索公司下一代 3D 堆叠近存计算处理器架构，并从硬件设计挑战中提炼学术问题。
  - **成果**: 相关研究已投稿 ASPLOS 2026，目前处于审稿阶段。
  - **当前工作**: 探索 HBF 在大语言模型推理中的应用，并研究相应的内存管理方法。

  编译器团队成员 *2026 年 3 月 – 2026 年 6 月*

  - **职责**: 为公司内部的 3D 堆叠近存计算处理器开发编译器优化模块，负责面向大语言模型推理的权重布局自动选择和 GEMM 调度。
  - **技术难点**: 同时考虑 DRAM 行缓冲访问时序和计算流水线，优化权重分块、对齐及调度，减少行缓冲冲突造成的停顿。
  - **成果**: 开发轻量级布局搜索模块并集成到公司编译器，相关研究形成本科毕业论文。模型评估显示，与未考虑行缓冲的行优先基线相比，大规模 Linear 算子提速 **3.60–5.86**×；GLM-4.7 MoE 的端到端 GEMM 提速 **2.01**×，DRAM 存储开销仅增加 0.63%。

- **杜克大学，CEI 研究中心** 2025 年 6 月 – 2025 年 9 月

  科研实习生 导师：陈怡然教授

  - **职责**: 负责扩散语言模型研究小组和 DPad 项目，提出加快推理的 suffix dropout 方法，并独立开发开源代码库。
  - **成果**: 在实习期间完成 DPad 研究，以共同第一作者身份发表 ICLR 2026 论文。

- **上海期智研究院** 2024 年 3 月 – 2025 年 6 月

  科研实习生 导师：高鸣宇教授

  - **职责**: 接手 CROPHE 项目后逐步负责项目整体推进，研发面向全同态加密加速器的内存感知调度方法和统一处理单元。
  - **成果**: 以共同第一作者身份发表 HPCA 2026 论文 CROPHE，并作为共同作者发表 DATE 2025 论文，提出统一的全同态加密向量处理单元。

技术与语言能力

- **编程**：C/C++、Python；**硬件描述语言**：Verilog、Chisel；**汇编**：RISC-V。
- **工具**：Vivado、Quartus、gem5、Git、MATLAB、LaTeX。
- **IELTS**：总分 7.5；听力 7.5、阅读 9.0、写作 6.5、口语 6.5。
- **GRE**：总分 330；语文 160（前 16%）、数学 170（前 6%）。

论文与个人贡献

（† 表示共同第一作者、同等贡献）

[1] **Xinhua Chen**†, Sitao Huang†, Cong Guo†, Chiyue Wei, Yintao He, Jianyi Zhang, Hai "Hellen" Li, Yiran Chen. *DPad*：基于后缀丢弃的高效扩散语言模型。国际学习表征会议（**ICLR 2026**）[链接]

- **工作概述**: 提出无需额外训练的扩散语言模型推理方法，结合滑动窗口和基于距离的 suffix dropout，减少不必要的后缀注意力计算。
- **个人贡献（项目负责人）**：负责项目整体研究，提出 suffix dropout 方法，减少低熵后缀词元对前缀注意力计算的干扰，并独立开发开源代码库。
- **结果**: 在 LLaDA 和 Dream 上结合其他兼容的解码优化，保持相近精度，推理速度最高达到原始扩散语言模型的 61.4 倍。
- **影响**: 获蚂蚁集团、AMD 和 Meta 邀请开展合作，研究成果获机器之心等科技媒体报道。Suffix dropout 也为扩散语言模型的训练方法提供了改进思路。

[2] **Xinhua Chen**†, Jiangbin Dong†, Hongren Zheng, Tian Tang, Mingyu Gao*. *CROPHE*：面向全同态加密加速器的跨算子数据流优化。 IEEE 高性能计算机体系架构国际研讨会（**HPCA 2026**）[链接]

- **工作概述**: 面向全同态加密加速器的内存瓶颈，结合统一处理单元和跨算子调度，复用硬件资源，并在时间和空间上组织流水执行。
- **个人贡献**: 接手项目后逐步负责整体研究；参与开发内存感知调度器，通过循环重排和分块减少 DRAM 访问量及 SRAM 需求；设计支持正向、逆向 NTT 和 MAC 运算的处理单元。
- **结果**: 与论文评估的先进加速器相比，速度提升 1.77–4.86 倍。

[3] Jiangbin Dong, **Xinhua Chen**, Mingyu Gao*. 用于全同态加密的统一向量处理单元。欧洲设计自动化与测试会议（**DATE 2025**）[链接]

- **工作概述**: 提出面向全同态加密的统一向量处理单元，通过硬件复用和运算通道间的互连网络，同时支持 NTT 和自同构运算。
- **个人贡献**: 参与将自同构运算拆解为移位操作，设计运算通道间的置换网络，并共同提出统一向量处理单元。
- **结果**: 与论文评估的设计相比，通道间网络的面积和功耗最多分别降低 9.4 倍和 6.0 倍；完整处理单元的面积和功耗最多分别降低 1.2 倍和 1.1 倍。

[4] Ruoxi Zhu, Shusong Xu, Peiye Liu, Sicheng Li, Yanheng Lu, Dimin Niu, Zihao Liu, Zihao Meng, Li Zhiyong, **Xinhua Chen**, Yibo Fan*. 用于高动态范围色调映射的零样本结构保持扩散模型。 IEEE/CVF 计算机视觉与模式识别会议（**CVPR 2024，Highlight**）[链接]

- **工作概述**: 提出零样本 HDR 色调映射方法，无需成对的 HDR/LDR 训练数据，即可将预训练扩散模型用于 HDR 图像，并保留图像结构。
- **个人贡献**: 使用 TMQI 等指标评估色调映射质量。

[5] Zihao Chen†, Zihan Lin†, **Xinhua Chen†**, Zhiyi Liu, Changxu Liu, Yuxuan Qiao, Yifei Feng, Junjie Zuo, Yifan Song, Fan Yang*. *Spec2Doc2RTL*：以自然语言为中间表示，从设计规格生成 *RTL*。 International Symposium of Electronics Design Automation（**ISEDA 2025**）[链接]

- **工作概述**: 先将设计规格转为自然语言设计文档，再生成 RTL；两阶段均采用分层任务分解和迭代反馈。
- **个人贡献**: 参与设计递归任务分解方法，并共同开发基于 GPT-4 Turbo 的开源框架，利用迭代反馈生成设计文档和 RTL。
- **结果**: 在 Revisiting VerilogEval 上，零样本 pass@1 达到 **78.8%**，高于 GPT-4 Turbo 的 60.3%；还展示了生成 RISC-V CPU 和 NTT 电路的能力。

[6] Yi Sun†, **Xinhua Chen**†, Xinglong Yu, Wenxuan Zhang, Yifan Zhao, Honglin Kuang, Jun Han*. 面向混合键合全同态加密加速器的滑动窗口调度。 Great Lakes Symposium on VLSI（**GLSVLSI 2025**）[链接]

- **工作概述**: 针对采用混合键合技术的全同态加密加速器，提出滑动窗口调度方法，以更细粒度的数据流安排减少数据搬运和同步开销。
- **个人贡献**: 搭建实验框架，负责几乎所有实验。
- **结果**: 在相同硬件配置下，仿真结果显示，ResNet-20 和 ResNet-56 的隐私推理吞吐量比 H3 分别高 **77.5%** 和 **70.1%**。